Testing Psicologico

Lezione 2

Filippo Gambarota

@Università di Padova

Case Study 👨‍🚀

Un (fake) dataset

Il dataset `psych.csv` contiene un dataframe di dati simulati riguardo a **diagnosi psicologiche**, **questionari** e **variabili sociodemografiche**. Le variabili sono:

- `eta`: corrisponde all'età dei pazienti (età minima dei pazienti 10 anni)
- `diagnosi`: rappresenta la diagnosi psicologica
- `ses`: rappresenta lo status socio-economico
- `dep_score`: rappresenta il punteggio ad un questionario di depressione dove 0 è il punteggio minimo (assenza di aspetti depressivi) e 100 è il punteggio massimo di depressione.
- `ans_score`: rappresenta il punteggio ad un questionario di ansia dove 0 è il punteggio minimo (assenza di aspetti ansiosi) e 100 è il punteggio massimo di ansia
- `self_esteem_score`: rappresenta il punteggio ad item di autostima dove 1 è bassa autostima e 6 è alta autostima

Before starting...

- Importiamo il dataset (attenzione all'*estensione*, al *separatore* e agli *argomenti* della funzione che scegliete)
- Controllare struttura e tipo di variabili del dataset
- Controllare **anomalie** nel dataset (valori strani o mancanti) e sistemarli. Gli errori anche in raccolta dati sono sempre dietro l'angolo
  - nel caso di valori mancanti, rimuovere quelle righe (vedi la funzione `complete.cases()`)
  - nel caso di valori anomali, creare un nuovo dataset con le righe anomale e rimuoverle dal dataset principale
- Aggiungere una colonna che indica il numero del paziente da 1 a quanti sono i pazienti
- Aggiungere una colonna `eta_bin` che prende i valori di "maggiorenne" e "minorenne" in base all'età
- Rimuovere dal dataset le righe associate a pazienti con diagnosi `altro`

Before starting...

```r
dat <- read.csv("../../data/psych.csv", header = TRUE, sep = ";") # importare
```

```r
str(dat) # struttura e tipo di variabili
```

```
## 'data.frame':    185 obs. of  6 variables:
##  $ eta              : int  0 17 10 20 38 28 11 33 57 26 ...
##  $ diagnosi         : chr  "ocd" "ocd" "ansiasociale" "ocd" ...
##  $ ses              : chr  "medio" "alto" "alto" "alto" ...
##  $ dep_score        : int  0 5 37 0 65 100 45 100 76 90 ...
##  $ ans_score        : int  65 67 95 84 16 46 53 52 31 46 ...
##  $ self_esteem_score: int  2 4 4 3 6 5 1 2 1 2 ...
```

```r
# ?complete.cases # a cosa serve?
complete.cases(dat)
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [17] TRUE TRUE TRUE TRUE
##  [ reached getOption("max.print") -- omitted 165 entries ]
```

```r
dat <- dat[complete.cases(dat), ] # selezioniamo solo quelli senza valori mancanti
```

Before starting...

Abbiamo detto che l'età dovrebbe essere maggiore/uguale a 10 anni. Vediamo se abbiamo dei casi anomali:

```
dat[dat$eta < 10, ] # errori di codifica o raccolta dati
```

```
##    eta    diagnosi   ses dep_score ans_score self_esteem_score
## 1    0         ocd medio         0        65                 2
## 18   7 depressione  alto        90        43                 3
## 30   0 depressione medio        57        50                 4
##  [ reached 'max' / getOption("max.print") -- omitted 17 rows ]
```

```
dat_errori <- dat[dat$eta < 10, ] # dataset con errori
dat <- dat[dat$eta >= 10, ] # dataset senza errori
```

Continuiamo con il pre-processing...

```
dat$id <- 1:nrow(dat) # colonna che identifica il numero del paziente
```

```
dat$eta_bin <- ifelse(dat$eta >= 18, "maggiorenne", "minorenne")
```

```
dat <- dat[dat$diagnosi != "altro", ] # togliamo le diagnosi altro
```

Exploratory Data Analysis 👩‍🚀

EDA

- Calcoliamo delle statistiche descrittive appropriate per ogni tipologia di variabile
- Calcoliamo le frequenze relative delle `diagnosi`
- Calcoliamo le frequenze relative delle `diagnosi` condizionate al `ses`
- Facciamo un istogramma dei punteggi di `ansia` e `depressione`
- Facciamo un barplot dei punteggi di `autostima`
- Facciamo un barplot dei punteggi di `autostima` condizionati al tipo di `diagnosi`
- Calcoliamo `media`, `mediana` e `deviazione standard` e `coefficiente di variazione` dei punteggi di `depressione`, `ansia` e `autostima` per ogni `diagnosi`. Cosa notiamo?

EDA

```
summary(dat) # funzione utile ma molto generica
```

```
##       eta          diagnosi             ses              dep_score
##  Min.   :10.00   Length:132         Length:132         Min.   :  0.00
##  1st Qu.:18.00   Class :character   Class :character   1st Qu.: 30.50
##    ans_score     self_esteem_score       id           eta_bin
##  Min.   : 0.00   Min.   :1.000     Min.   :  1.00   Length:132
##  1st Qu.:33.75   1st Qu.:1.000     1st Qu.: 37.75   Class :character
##  [ reached getOption("max.print") -- omitted 4 rows ]
```

```
table(dat$ses)
```

```
##
##  alto basso medio
##    61    34    37
```

```
table(dat$diagnosi)
```

```
##
## ansiasociale     bipolare  depressione          ocd
##           27            8           77           20
```

EDA

```
f_diagnosi <- table(dat$diagnosi)/length(dat$diagnosi)
f_diagnosi
```

```
##
## ansiasociale     bipolare  depressione          ocd
##   0.20454545   0.06060606   0.58333333   0.15151515
```

```
sum(f_diagnosi)
```

```
## [1] 1
```

```
# provate ad usare ?prop.table()
```

```
ds_f <- table(dat$diagnosi, dat$ses) # assolute, come le relativizziamo? vedi prop.table()
ds_f
```

```
##
##                alto basso medio
##   ansiasociale   12     8     7
##   bipolare        2     1     5
##   depressione    42    18    17
##   ocd             5     7     8
```

```
prop.table(ds_f, margin = 1) # a cosa serve margin?
```

```
##
##                     alto     basso     medio
##   ansiasociale 0.4444444 0.2962963 0.2592593
##   bipolare     0.2500000 0.1250000 0.6250000
##   depressione  0.5454545 0.2337662 0.2207792
##   ocd          0.2500000 0.3500000 0.4000000
```

EDA

```
par(mfrow = c(1,3)) # per fare 2 grafici
hist(dat$ans_score)
hist(dat$ans_score)
barplot(table(dat$self_esteem_score), xlab = "dat$self_esteem_score")
```

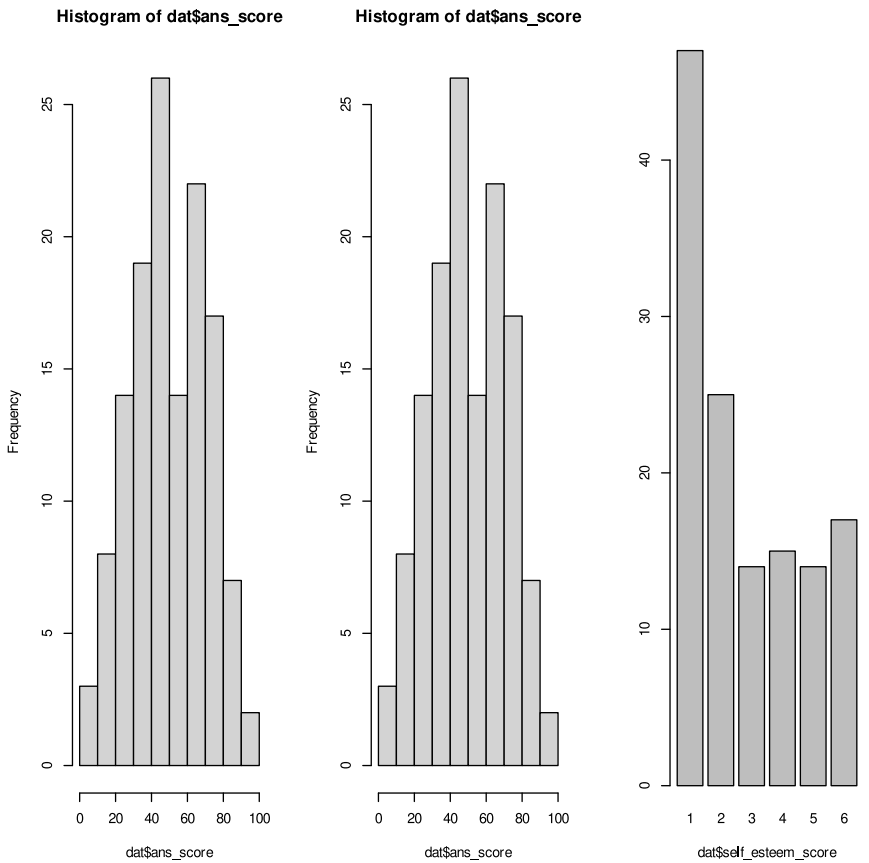

EDA

Il barplot condizionato è molto utile per esplorare visivamente la relazione tra due variabili categoriali:

```
barplot(table(dat$self_esteem_score, dat$diagnosi)) # quale è il problema qui?
```

EDA

Dobbiamo fare le frequenze relative per fare in modo che sia più efficacie:

```
freq_self_diag <- prop.table(table(dat$self_esteem_score, dat$diagnosi), 2)
barplot(freq_self_diag)
```

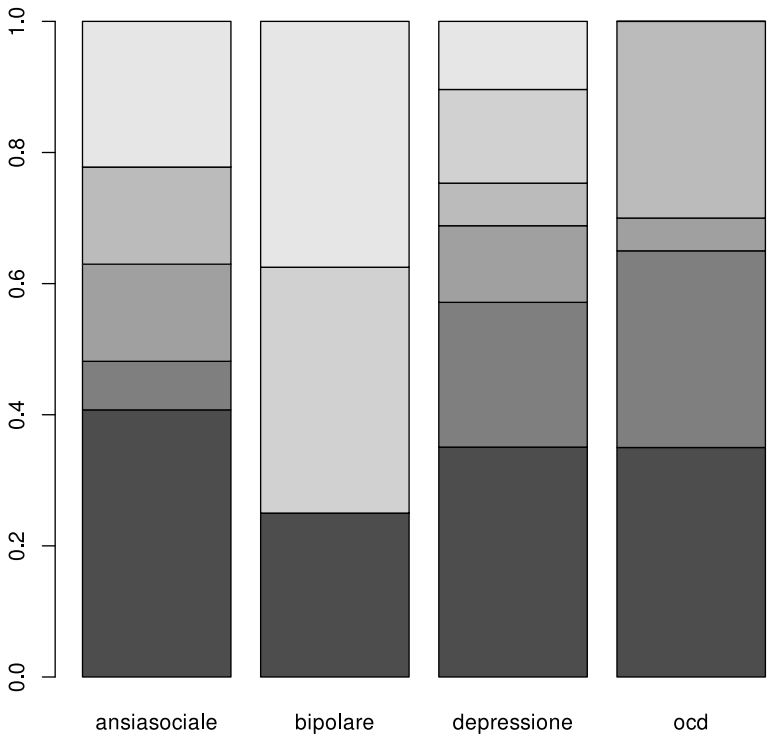

EDA

Facciamolo più carino usando `ggplot2` (Advanced)

```
ggplot(datf) +
  geom_col(aes(x = diagnosi, y = p, fill = factor(self_esteem_score)),
           color = "black", position = position_dodge()) +
  labs(fill = "Autostima") +
  ggthemes::theme_par()
```

EDA

Facciamo uno scatterplot di ansia e depressione:

```
plot(dat$ans_score, dat$dep_score, pch = 19)
```

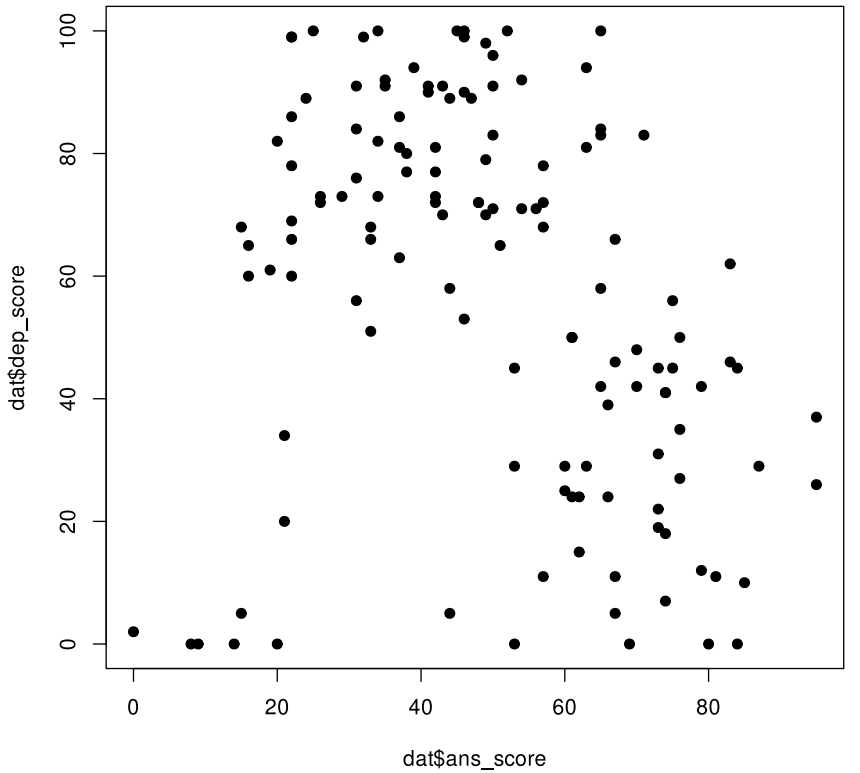

EDA

Più carino con le distribuzioni marginali:

```
plt <- ggplot(dat, aes(x = ans_score, y = dep_score)) +
  geom_point() +
  ggthemes::theme_par()

ggExtra::ggMarginal(plt, type = "hist")
```

EDA

```
par(mfrow = c(2, 1))
hist(dat$dep_score)
hist(dat$ans_score)
```

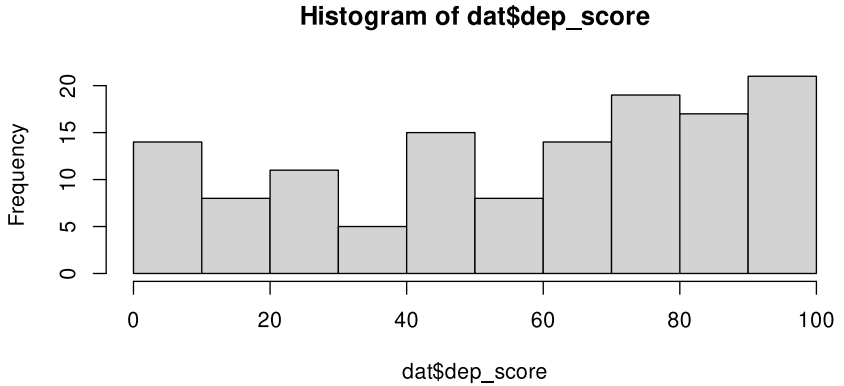

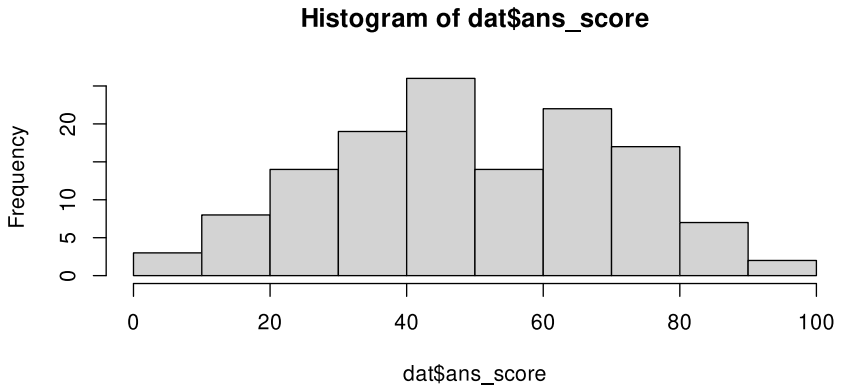

EDA

Calcoliamo un punteggio di "malessere" medio facendo la media dei punteggi di ansia e depressione per ogni soggetto:

```
distress <- apply(dat[, c("ans_score", "dep_score")], 1, mean)
dat$distress <- distress
```

```
summary(dat$distress)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.00   45.50   57.25   53.47   63.62   82.50
```

```
hist(dat$distress)
```

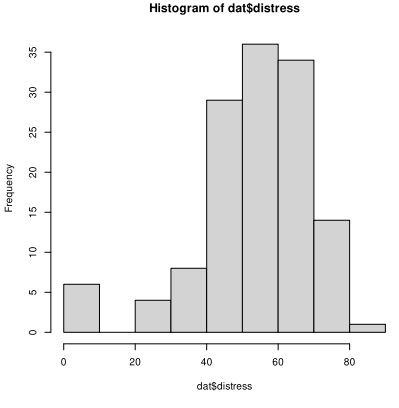

EDA

Calcoliamo `media`, `mediana` e `deviazione standard` e `coefficiente di variazione` dei punteggi di `depressione`, `ansia` e `autostima` per ogni `diagnosi`. Cosa notiamo?

```
mean(dat$dep_score[dat$diagnosi == "ansiasociale"])
```

```
## [1] 40.74074
```

```
mean(dat$dep_score[dat$diagnosi == "bipolare"])
```

```
## [1] 7.625
```

```
# ...
```

Questo non è il modo più efficace e compatto... 😿

EDA

Possiamo usare la funzione `?tapply()` per applicare una `funzione` a `y` splittando per `x`:

```
cv <- function(x){
  # https://it.wikipedia.org/wiki/Coefficiente_di_variazione
  sd(x, na.rm = TRUE) / abs(mean(x, na.rm = TRUE))
}

# depressione
tapply(X = dat$dep_score, INDEX = dat$diagnosi, FUN = mean, na.rm = TRUE)
```

```
## ansiasociale     bipolare  depressione          ocd
##     40.74074      7.62500     79.62338     12.50000
```

```
tapply(X = dat$dep_score, INDEX = dat$diagnosi, FUN = median, na.rm = TRUE)
```

```
## ansiasociale     bipolare  depressione          ocd
##           42            1           80           11
```

```
tapply(X = dat$dep_score, INDEX = dat$diagnosi, FUN = sd, na.rm = TRUE)
```

```
## ansiasociale     bipolare  depressione          ocd
##     9.677860    12.648405    13.298238     9.439558
```

```
tapply(X = dat$dep_score, INDEX = dat$diagnosi, FUN = cv)
```

```
## ansiasociale     bipolare  depressione          ocd
##    0.2375475    1.6588072    0.1670142    0.7551647
```

EDA - Extra

Facciamo un modo ancora più compatto! 😄

```
my_summary <- function(x){
  c(
    mean = mean(x, na.rm = TRUE),
    median = median(x, na.rm = TRUE),
    sd = sd(x, na.rm = TRUE),
    cv = sd(x, na.rm = TRUE) / abs(mean(x, na.rm = TRUE))
  )
}

tapply(dat$ans_score, dat$diagnosi, my_summary)
```

```
## $ansiasociale
##       mean     median         sd         cv
## 70.8148148 73.0000000  9.7390453  0.1375284
##
## $bipolare
##       mean     median         sd         cv
## 13.5000000 14.5000000  7.4642003  0.5529037
##
## $depressione
##       mean     median         sd         cv
## 40.6233766 42.0000000 13.8905865  0.3419358
##
## $ocd
##       mean     median         sd         cv
## 71.3000000 73.0000000 12.6370383  0.1772376
```

```
# ... così per tutte le variabili
```

EDA - Extra Extra Extra

Facciamo un modo ancooooooora più compatto! 😱

```
ys <- list(depressione = dat$dep_score,
           ansia = dat$ans_score,
           autostima = dat$self_esteem_score)

lapply(ys, function(x) tapply(x, dat$diagnosi, my_summary))
```

```
## $depressione
## $depressione$ansiasociale
##       mean     median         sd         cv
## 40.7407407 42.0000000  9.6778597  0.2375475
##
## $depressione$bipolare
##      mean    median        sd        cv
##  7.625000  1.000000 12.648405  1.658807
##
## $depressione$depressione
##       mean     median         sd         cv
## 79.6233766 80.0000000 13.2982379  0.1670142
##
## $depressione$ocd
##       mean     median         sd         cv
## 12.5000000 11.0000000  9.4395584  0.7551647
##
##
## $ansia
## $ansia$ansiasociale
##       mean     median         sd         cv
## 70.8148148 73.0000000  9.7390453  0.1375284
##
## $ansia$bipolare
##       mean     median         sd         cv
## 13.5000000 14.5000000  7.4642003  0.5529037
##
## $ansia$depressione
##       mean     median         sd         cv
## 40.6233766 42.0000000 13.8905865  0.3419358
##
## $ansia$ocd
##       mean     median         sd         cv
## 71.3000000 73.0000000 12.6370383  0.1772376
##
##
```